支持向量机

西南财经大学
龚梓阳　张馨玥
2019 年 4 月 29 日

定义

假设给定一个特征空间上的训练数据集

$$T = \{(\vec{x_1}, y_1), (\vec{x_2}, y_2), \ldots, (\vec{x_N}, y_N)\} \tag{1}$$

其中，$\vec{x_i} \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \ldots, N$，$\vec{x_i}$ 为第 i 个特征向量，也称为实例，y_i 为 $\vec{x_i}$ 的类标记，当 $y_i = +1$ 时，称 $\vec{x_i}$ 为正例；当 $y_i = -1$ 时，称 $\vec{x_i}$ 为负例，$(\vec{x_i}, y_i)$ 称为样本点。
学习的目标是在特征空间中找到一个分离超平面，能够将实例分到不同的类。分离超平面对应于方程 $\vec{w}^T\vec{x} + b = 0$，它由法向量 $\vec{w}$ 和截距 b 决定，可用 $(\vec{w}, b)$ 表示。分离超平面将特征空间划分为两部分，一部分是正类，另一部分是负类。

1. 线性可分支持向量机

线性可分支持向量机

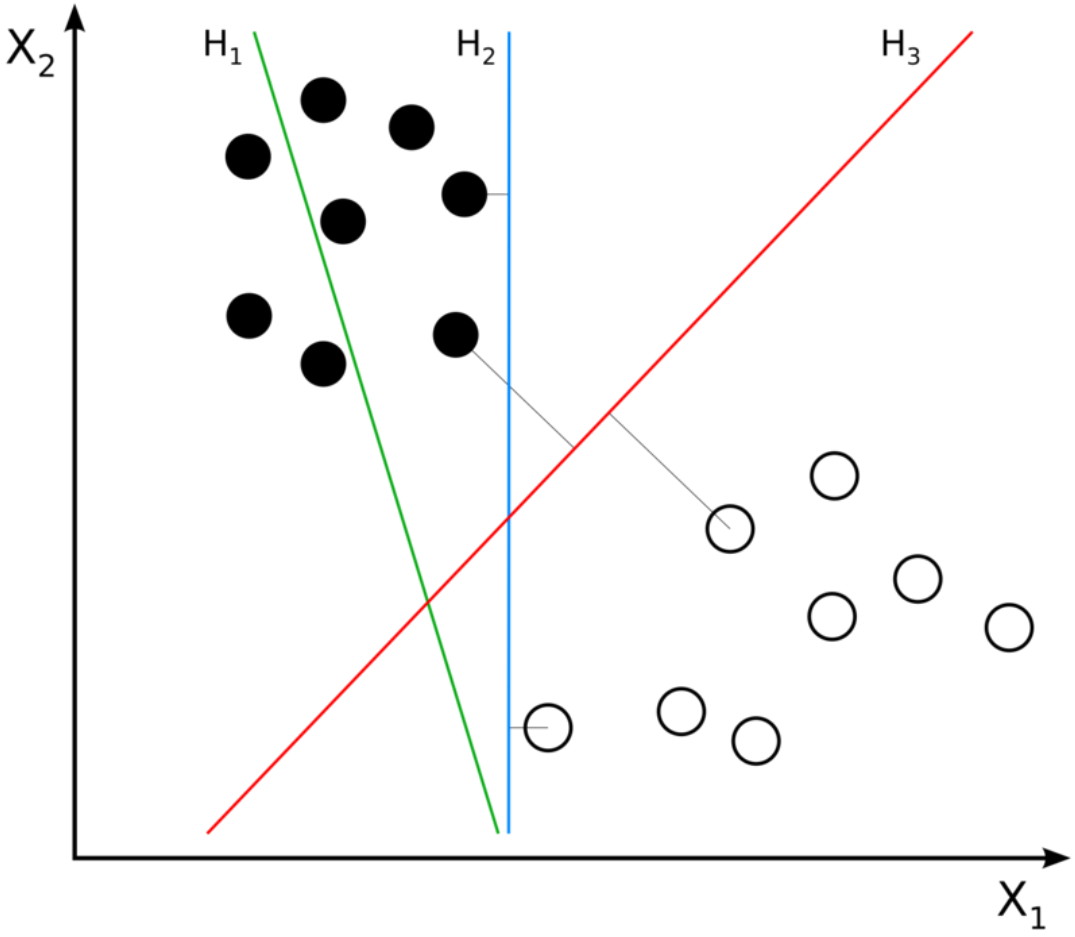

图: 存在多个划分超平面将两类训练样本分开

函数间隔与几何间隔 (1)

定义

函数间隔 对于给定的训练数据集 T 和超平面 $(\vec{w}, b)$，定义超平面 $(\vec{w}, b)$ 关于样本点 $(\vec{x}_i, y_i)$ 的函数间隔为

$$\hat{\gamma}_i = y_i \left(\vec{w}^T \vec{x}_i + b\right) \tag{2}$$

定义超平面 $(\vec{w}, b)$ 关于训练数据集 T 的函数间隔为超平面 $(\vec{w}, b)$ 关于 T 中所有样本点 $(\vec{x}_i, y_i)$ 的函数间隔之间的最小值，即

$$\hat{\gamma} = \min_{i=1,\ldots,N} \hat{\gamma}_i \tag{3}$$

函数间隔与几何间隔 (2)

定义

几何间隔 对于给定的训练数据集 T 和超平面 $(\vec{w}, b)$，定义超平面 $(\vec{w}, b)$ 关于样本点 $(\vec{x}_i, y_i)$ 的几何间隔为

$$\gamma_i = \frac{y_i \left(\vec{w}^T \vec{x}_i + b\right)}{\|\vec{w}\|} \tag{4}$$

定义超平面 $(\vec{w}, b)$ 关于训练数据集 T 的几何间隔为超平面 $(\vec{w}, b)$ 关于 T 中所有样本点 $(\vec{x}_i, y_i)$ 的几何间隔之间的最小值，即

$$\gamma = \min_{i=1,\ldots,N} \gamma_i \tag{5}$$

间隔最大化

$$\max \hat{\gamma}, \quad \text{s.t.} \quad y_i \left(\vec{w}^T \vec{x}_i + b\right) \geq \hat{\gamma}, i = 1, \ldots, N \tag{6}$$

$$\max \frac{1}{2} \|\vec{w}\|^2, \quad \text{s.t.} \quad y_i \left(\vec{w}^T \vec{x}_i + b\right) \geq 1, i = 1, \ldots, N \tag{7}$$

支持向量和间隔边界

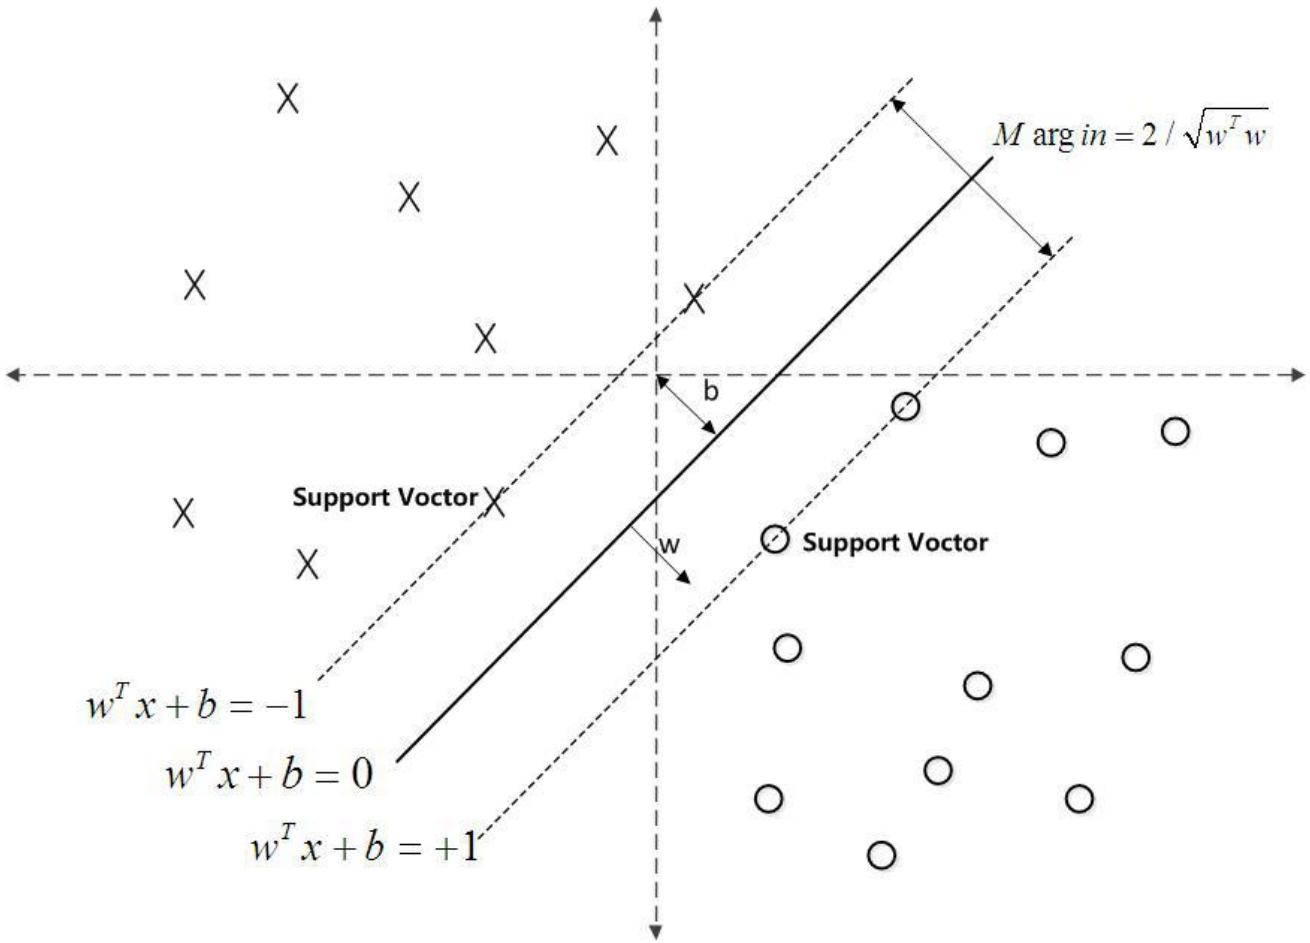

图: 支持向量和间隔边界

2. 线性支持向量机

线性支持向量机

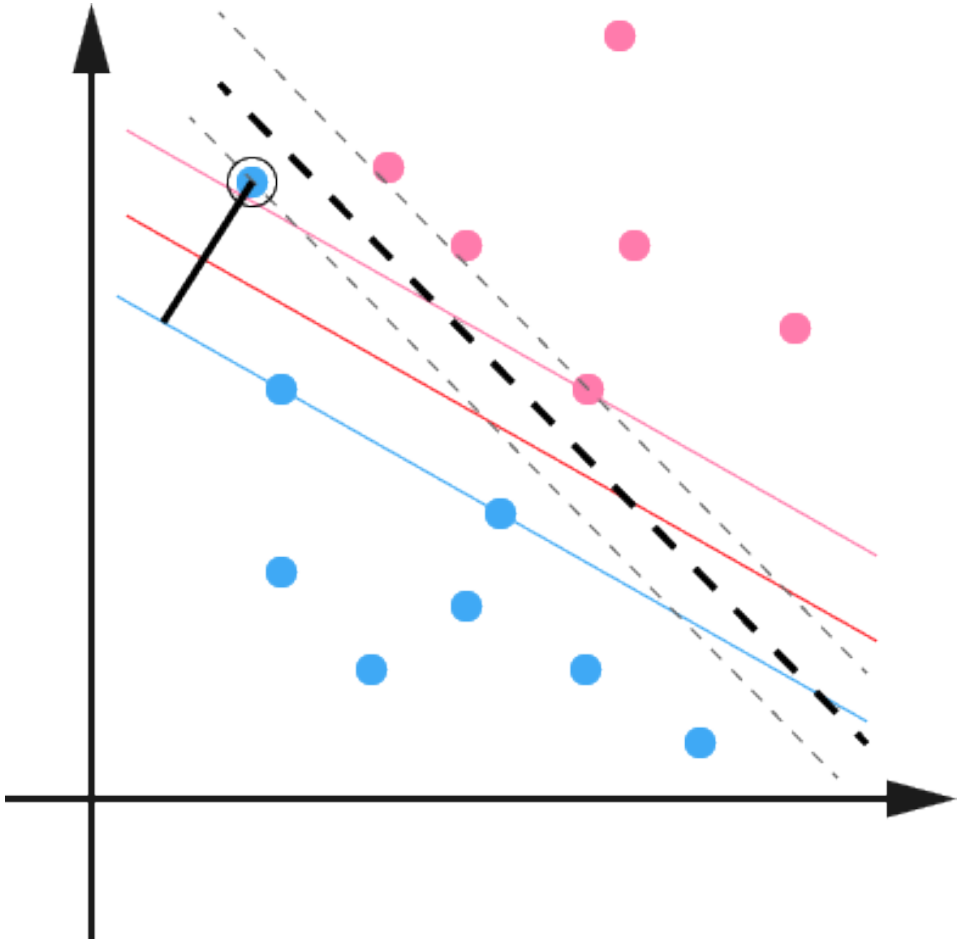

图: 软间隔示意图，黑色圈出不满足约束的样本

软间隔最大化

$$
\begin{aligned}
\min \quad & \frac{1}{2}\|\vec{w}\|^2 + C\sum_{i=1}^{N}\xi_i \\
\text{s.t.} \quad & y_i\left(\vec{w}^T\vec{x}_i + b\right) \geq 1 - \xi_i, i = 1, \ldots, N \\
& \xi_i \geq 0, i = 1, 2, \ldots, N
\end{aligned}
\tag{8}
$$

- ξ_i 称为松弛变量（slack variable），对应数据点 $\vec{x}_i$ 允许偏离函数间隔的量。
- C 是一个参数，用于控制目标函数中两项（“寻找 margin 最大的超平面”和“保证数据点偏差量最小”）之间的权重。

3. 非线性支持向量机

特征空间的隐式映射——核函数 (1)

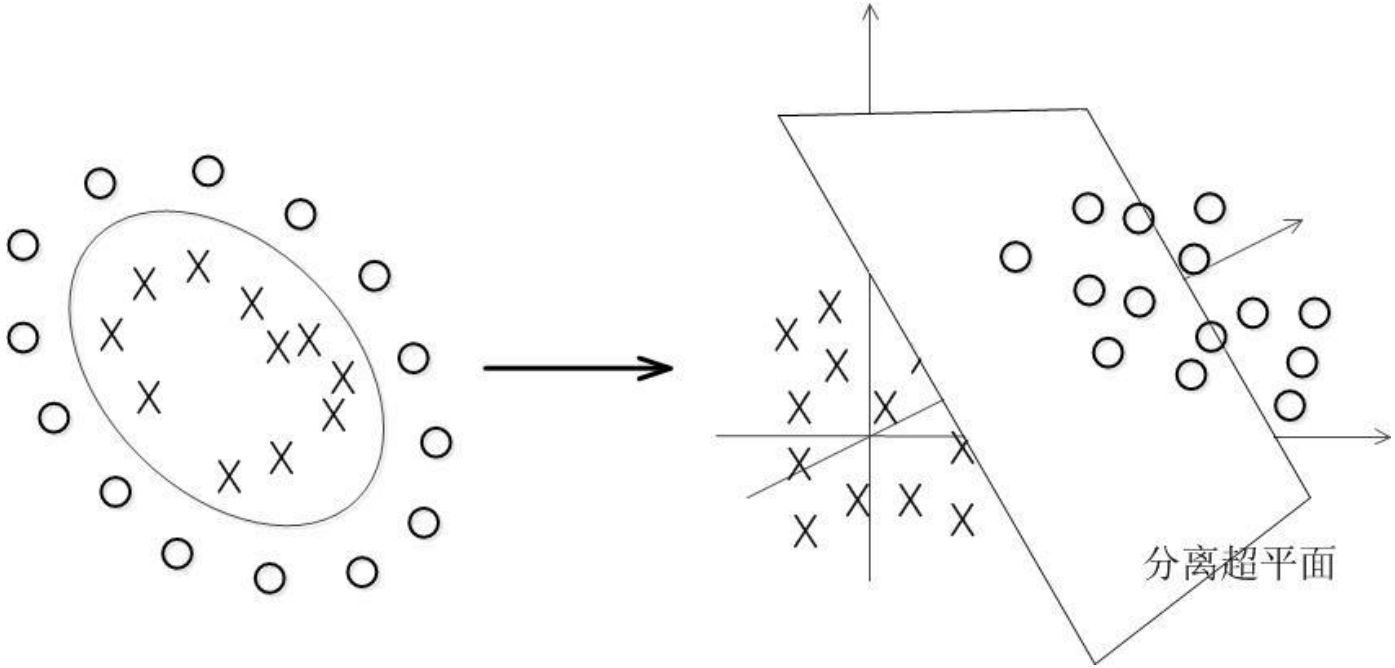

图: 特征空间的隐式映射——核函数

特征空间的隐式映射——核函数 (2)

定义

核函数 设 $\mathcal{X}$ 是输入空间（欧氏空间 R^n 的子集或离散集合），又设 $\mathcal{H}$ 为特征空间（希尔伯特空间），如果存在一个 $\mathcal{X} \to \mathcal{H}$ 的映射

$$\phi(\vec{x}) : \mathcal{X} \to \mathcal{H} \tag{9}$$

使得对所有 $\vec{x}, \vec{z} \in \mathcal{X}$ ，函数 $K(\vec{x}, \vec{z})$ 满足条件

$$K(\vec{x}, \vec{z}) = \phi(\vec{x}) \cdot \phi(\vec{z}) \tag{10}$$

则称 $K(\vec{x}, \vec{z})$ 为核函数，$\phi(\vec{x})$ 为映射函数，式中 $\phi(\vec{x}) \cdot \phi(\vec{z})$ 为 $\phi(\vec{x})$ 和 $\phi(\vec{z})$ 的内积。

特征空间的隐式映射——核函数 (3)

所以，建立非线性支持向量机可分为两步：

1. 使用一个非线性映射将数据变换到一个特征空间 $\mathcal{H}$ ；
2. 在该特征空间使用线性支持向量机进行分类。

常见核函数

- 齐次多项式：$K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j)^d$。
- 非齐次多项式：$K(\vec{x}_i, \vec{x}_j) = (\vec{x}_i \cdot \vec{x}_j + 1)^d$。
- 高斯径向基函数：$K(\vec{x}_i, \vec{x}_j) = \exp(-\gamma \|\vec{x}_i - \vec{x}_j\|^2)$，其中 $\gamma > 0$，有时参数化表示 $\gamma = \frac{1}{2\sigma^2}$。
- 双曲正切：$K(\vec{x}_i, \vec{x}_j) = \tanh(\kappa \vec{x}_i \cdot \vec{x}_j + c)$，其中一些（而非所有）$\kappa > 0$ 且 $c < 0$。

4. 序列最小最优化算法

支持向量机学习算法 (1)

1. 选取适当的核函数 $K(\vec{x}, \vec{z})$ 和适当的参数 C，构造并求解最优化问题

$$
\begin{aligned}
\min_{\vec{\alpha}} \quad & \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j K(\vec{x}_i, \vec{x}_j) - \sum_{i=1}^{N}\alpha_i \\
\text{s.t.} \quad & \sum_{i=1}^{N} y_i\alpha_i = 0 \\
& 0 \le \alpha_i \le C, i = 1, 2, \ldots, N
\end{aligned}
\tag{11}
$$

求得最优解 $\vec{\alpha}^* = \left(\alpha_1^*, \alpha_2^*, \ldots, \alpha_N^*\right)^T$。

支持向量机学习算法 (2)

2 选择 $\vec{\alpha}^*$ 的一个正分量 $0 \leq \alpha_j^* \leq C$ ，计算

$$b^* = y_j - \sum_{i=1}^{N} \alpha^* y_i K(\vec{x}_i, \vec{x}_j) \tag{12}$$

3 构造决策函数:

$$f(\vec{x}) = sign\left(\sum_{i=1}^{N} \alpha_i^* y_i K\left(\vec{x}_i, \vec{x}_j\right) + b^*\right) \tag{13}$$

凸二次规划的对偶问题

$$
\begin{aligned}
\min_{\vec{\alpha}} \quad & \frac{1}{2}\sum_{i=1}^{N}\sum_{j=1}^{N}\alpha_i\alpha_j y_i y_j K\left(\vec{x}_i, \vec{x}_j\right) - \sum_{i=1}^{N}\alpha_i \\
\text{s.t.} \quad & \sum_{i=1}^{N} y_i\alpha_i = 0 \\
& 0 \le \alpha_i \le C, i = 1, 2, \ldots, N
\end{aligned}
\tag{14}
$$

坐标上升法

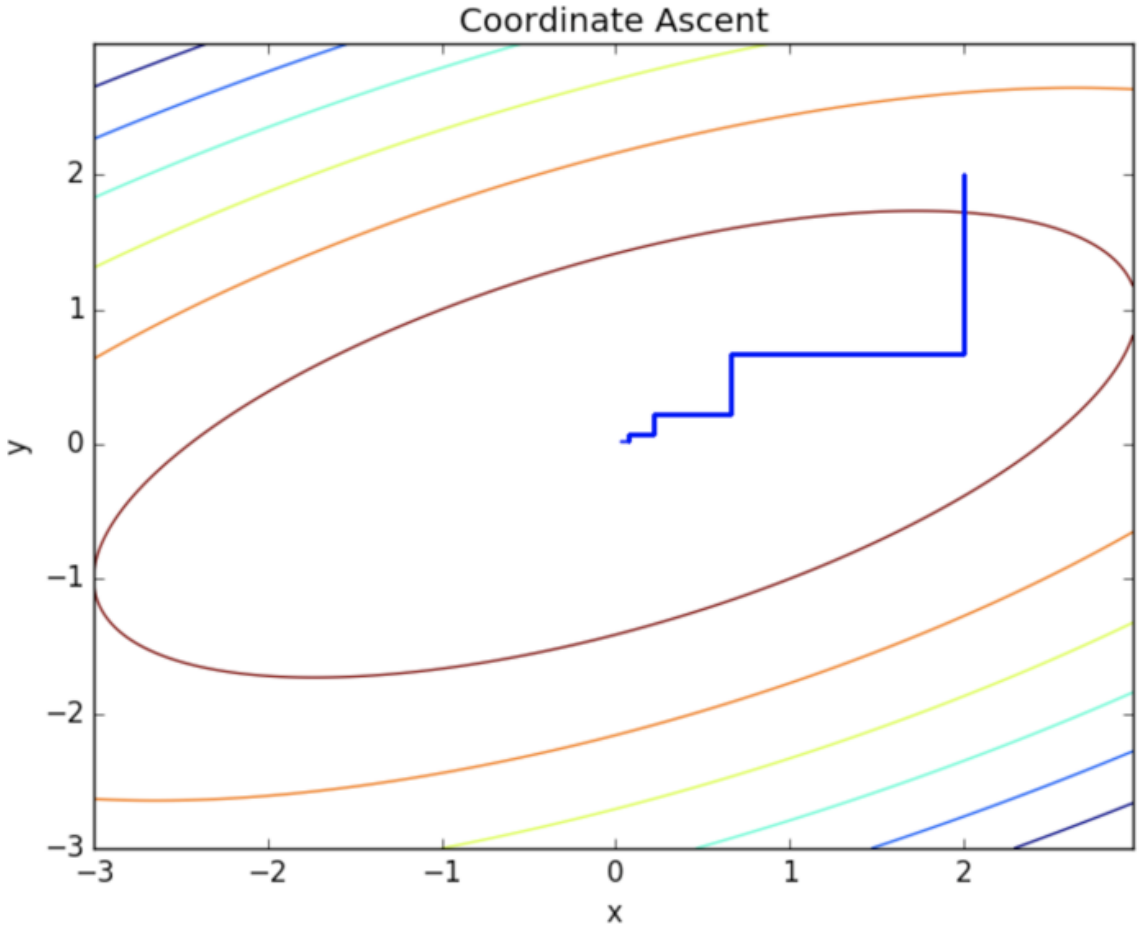

KKT 条件 (1)

定义

若一个最优化问题，满足：

- $h_j(x^*) = 0, j = 1, \ldots, p, \quad g_k(x^*) \leq 0, k = 1, \ldots, q$
- $\Delta f(x^*) + \sum_{j=1}^{p} \lambda_j \Delta h_j(x^*) + \sum_{k=1}^{q} \mu_k \Delta g_k(x^*) = 0, \lambda_j \neq 0, \mu_k \geq 0, \mu_k g_k(x^*) = 0$

则为满足 KKT 条件。

它是一个非线性规划（Nonlinear Programming）问题能有最优化解法的必要和充分条件。

例

KKT 条件 (2)

$$
\begin{aligned}
\alpha_i = 0 &\Leftrightarrow y_i u_i \geq 1 \\
0 < \alpha_i < C &\Leftrightarrow y_i u_i = 1 \\
\alpha_i = C &\Leftrightarrow y_i u_i \leq 1
\end{aligned}
\tag{15}
$$

序列最小最优化算法 (1)

由于目标函数为凸函数，一般的优化算法都通过梯度方法一次优化一个变量求解二次规划问题的最大值，但是，对于以上问题，由于限制条件 $\sum_{i=1}^{n} y_i \alpha_i = 0$ 存在，当某个 α_i 从 α_i^{old} 更新到 α_i^{new} 时，上述限制条件即被打破。为了克服以上的困难，SMO 采用一次更新两个变量的方法。

假定在某一次迭代中，需要更新 $\vec{x_1}$ 和 $\vec{x_2}$ 对应的拉格朗日乘子 α_1，α_2，那么这个小规模的二次规划问题写为：

$$
\begin{aligned}
\min_{\vec{\alpha}} \quad & (\alpha_1 + \alpha_2) + \sum_{i=3}^{n} \alpha_i - \frac{1}{2} \left\| \alpha_1 y_1 \phi(x_1) + \alpha_2 y_2 \phi(x_2) + \sum_{i=3}^{n} \alpha_i y_i \phi(x_1) \right\| \\
\text{s.t.} \quad & \alpha_1 y_1 + \alpha_2 y_2 = -\sum_{i=3}^{n} \alpha_i y_i \\
& 0 \le \alpha_i \le C, i = 1, 2
\end{aligned}
\tag{16}
$$

序列最小最优化算法 (2)

1. 计算上下界 L 和 H:

$$L = \max\left(0, \alpha_2^{old} - \alpha_1^{\text{old}}\right), H = \min\left(C, C + \alpha_2^{\text{old}} - \alpha_1^{\text{old}}\right), y_1 \neq y_2 \tag{17}$$

$$L = \max\left(0, \alpha_2^{old} + \alpha_1^{old} - C\right), H = \min\left(C, \alpha_2^{old} + \alpha_1^{old}\right), y_1 = y_2 \tag{18}$$

2. 计算其拉格朗日函数的二阶导数:

$$\eta = 2\phi\left(x_1\right)^T \phi\left(x_2\right) - \phi\left(x_1\right)^T \phi\left(x_1\right) - \phi\left(x_2\right)^T \phi\left(x_2\right) \tag{19}$$

3. 更新其拉格朗日函数的二阶导数

$$\begin{aligned} \alpha_2^{new} &= \alpha_2^{\text{old}} - \frac{y_2(E_1 - E_2)}{\eta} \\ E_i &= g^{\text{old}}\left(x_i\right) - y_i \end{aligned} \tag{20}$$

序列最小最优化算法 (3)

4 计算变量 α_2：

$$\alpha^{temp} = \begin{cases} H, & \text{if } \alpha_2^{\text{new}} \geq H \\ \alpha_2^{\text{new}}, & \text{if } L \leq \alpha_2^{\text{new}} \leq H \\ L, & \text{if } \alpha_2^{\text{new}} \leq L \end{cases} \tag{21}$$

选取哪些乘子进行更新呢?

1. 先“扫描”所有乘子，把第一个违反 KKT 条件的作为更新对象，令为 α_2；
2. 在所有不违反 KKT 条件的乘子中，选择使 $|E_1 - E_2|$ 最大的 α_1 进行更新，使得能最大限度增大目标函数的值（类似于梯度下降。此外 $E_i = u_i - y_i$，而 $u = \vec{w} \cdot \vec{x} - b$，求出来的 E 代表函数 u_i 对输入 $\vec{x_i}$ 的预测值与真实输出类标记 y_i 之差）。

最后，每次更新完两个乘子的优化后，都需要再重新计算 b，及对应的 E_i 值。

5. 支持向量机的优缺点

支持向量机的优点

- 在高维空间中非常高效
- 即使在数据维度比样本数量大的情况下仍然有效
- 在决策函数（称为支持向量）中使用训练集的子集，因此它也是高效利用内存的

支持向量机的缺点

- 如果特征数量比样本数量大得多，在选择核函数时要避免过拟合，而且正则化项是非常重要的
- 支持向量机不直接提供概率估计，这些都是使用昂贵的五次交叉验算计算的

6. 支持向量机的推广

多分类问题

- 一对一法（One agains one）
- 一对多法（One vs the rest）

不平衡问题

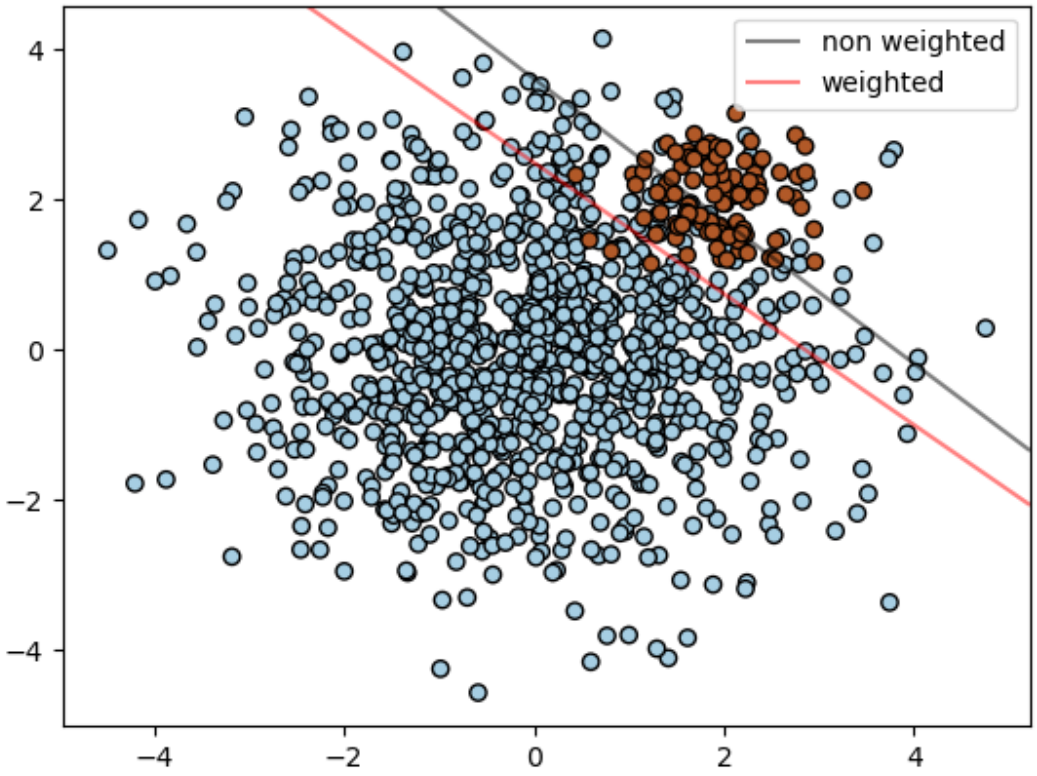

得分与概率

- Wu, Lin and Weng, “Probability estimates for multi-class classification by pairwise coupling”, JMLR 5:975-1005, 2004.
- Platt “Probabilistic outputs for SVMs and comparisons to regularized likelihood methods”.

异常值检测

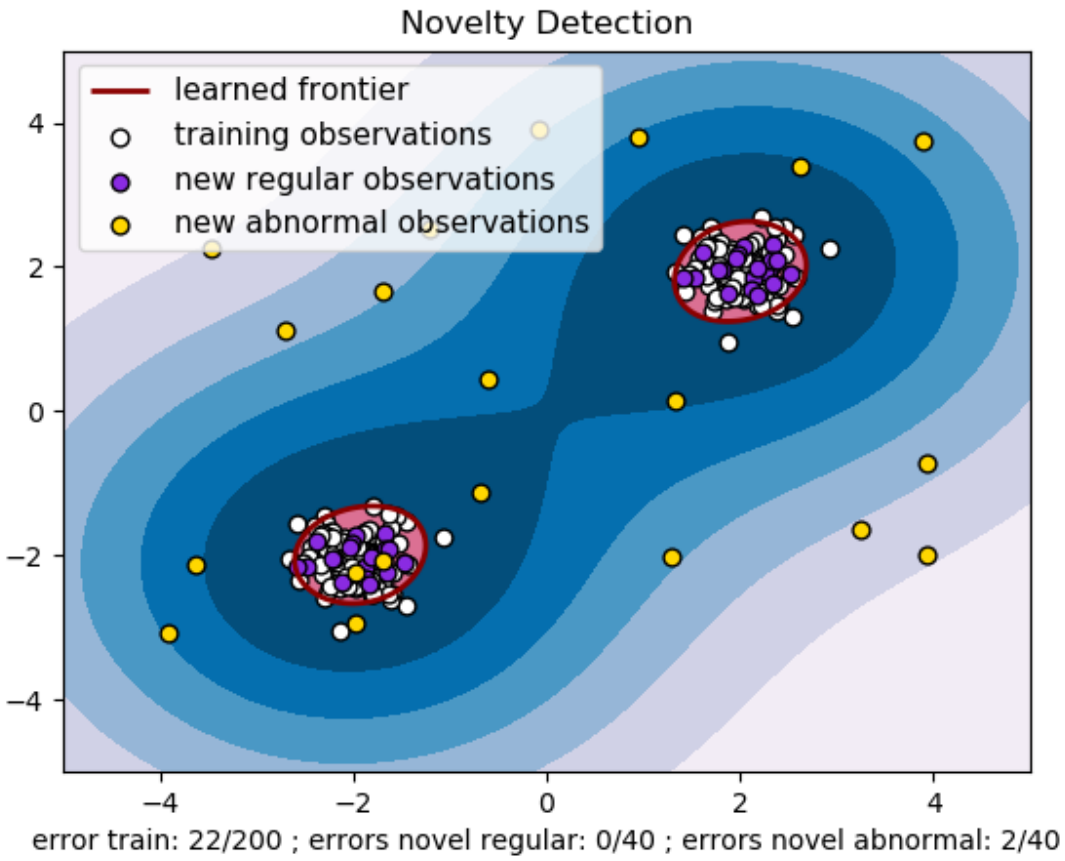

图: 异常值检测：单类 SVM

支持向量回归 (1)

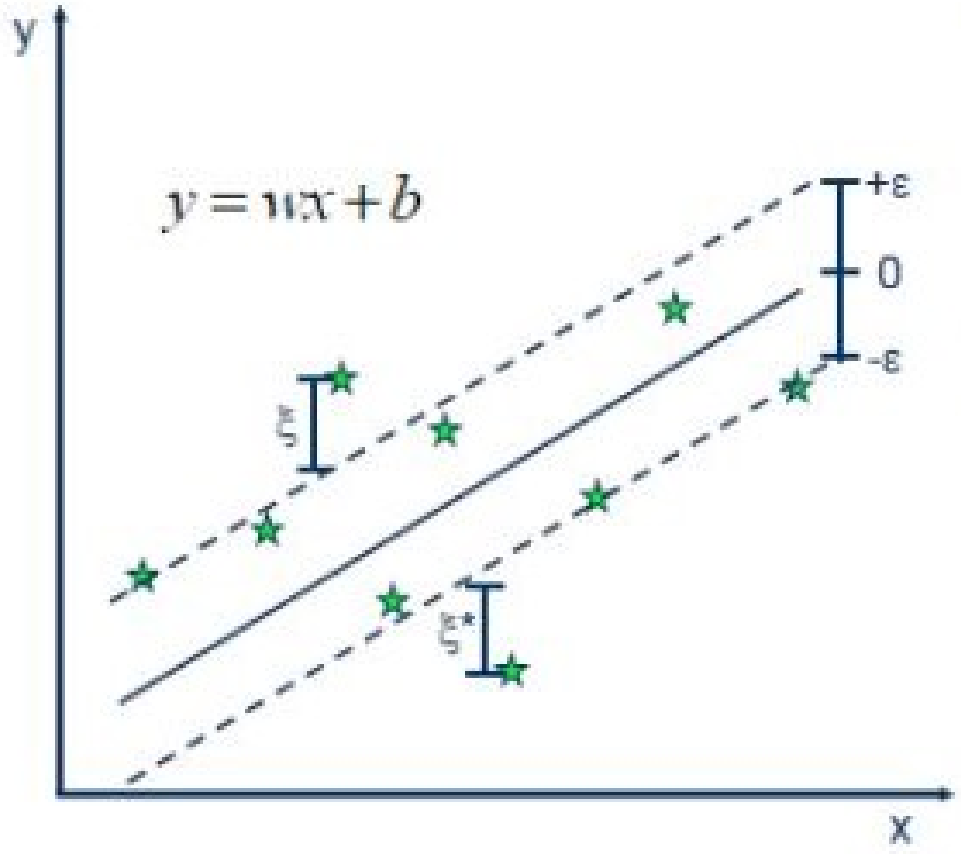

图: 支持向量回归示意图，虚线显示出 ϵ 间隔带，落入其中的样本不计算损失

支持向量回归 (2)

$$
\begin{aligned}
\min_{\vec{w},b,\zeta,\zeta^*} \quad & \frac{1}{2}w^T w + C\sum_{i=1}^{N}(\zeta_i + \zeta_i^*) \\
\text{s.t.} \quad & y_i - \vec{w}^T\phi(x_i) - b \le \varepsilon + \zeta_i \\
& \vec{w}^T\phi(x_i) + b - y_i \le \varepsilon + \zeta_i \\
& \zeta_i, \zeta_i^* \ge 0, i = 1, \ldots, N
\end{aligned}
\tag{22}
$$

7. 支持向量机的程序实现

参考文献

[1] 李航. 统计学习方法[M]. 北京: 清华大学出版社, 2012.

[2] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.

[3] PEDREGOSA F, VAROQUAUX G, GRAMFORT A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12:2825-2830.